Examen: OPI Analytics

Christian Jiménez Beltrán 24 de julio de 2017

Sección 1: Bebés

Para realizar la estimación de los bebes en la delegación Álvaro Obregón se implementó una regresión logística. Para implementar el modelo se revisó la base de datos del Censo de Población y Vivienda del 2010 en especifico el cuestionario ampliado de personas, donde se tomaron las variables de sexo ('sexo'), edad ('edad'), escolaridad acumulada ('escoacum'), número de hijos ('numhij') y el año ('fecnaca') y mes del último hijo nacido ('fecnacm').

La lógica que se siguió para elegir esas variables es: Edad, es bien sabido que las mujeres de edad entre 15 a 30 años están en el proceso donde es muy probable que se embaracen, además, aquí en México de las estadísticas del INEGI se encontró que en el 2014 21 años representa la edad de fecundidad promedio a nivel nacional; Escolaridad acumulada, me pareció que es una variable que está muy estrechamente relacionada con el número de hijos que tiene una mujer, esto se verifica por la ENADID; Número de hijos, es una variable que afecta la probabilidad de tener un hijo más.

La variable dependiente se formó por el año y mes del último hijo nacido, donde se hizo una variable dummy con valor de uno si la mujer tuvo un hijo en el año 2010 entre los meses de enero a junio.

La regresión logística usó las variables antes mencionadas con la variable dependiente, se buscó modelar la probabilidad de que una mujer tenga un bebé en los primeros 6 meses del año 2010. Como no se cuenta con información actual de las variables independientes se pretendió hacer una estimación de la situación actual de las mujeres del 2010, con estos datos ajustados se realizó la predicción donde se encontró que actualmente no hay bebés de 0 a 6 meses en la delegación Álvaro Obregón.

1. ¿En qué horarios hay mayor afluencia y en que estaciones?

Del análisis realizado se encontró que de lunes a viernes existe una mayor a fluencia en los horarios de 8 y 9 de la mañana y 6 a 7 de la tarde en las estaciones 18, 266 y . Mientras que, los sábados son a las 2 y 6 de la tarde en las estaciones 27 y 267 respectivamente, y domingos a las 9 de la mañana y 7 de la noche en las estaciones 27 y 266 respectivamente. La siguiente tabla resume lo antes mencionado.

Cuadro 1: Resultados				
	Crowded time	Station	Second Crowded time	Station
Monday	18	266	8	17
Tuesday	8	18	18	267
Wednesday	8	18	19	267
Thursday	8	27	19	266
Friday	8	18	18	266
Saturday	14	27	18	267
Sundan	10	266	Q	27

A continuación se presenta un histograma de la afluencia con respecto a la hora del día.

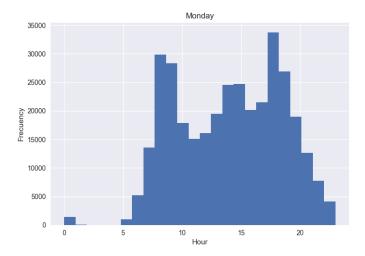


Figura 1: Histograma de afluencia respecto a la hora del día

El comportamiento de las horas con respecto a las estaciones de servicio se debe a la ubicación donde están, cerca de paseo de la reforma e insurgentes, donde pueden representar las zonas de trabajo de la gente y donde viven. Se puede decir que a las 8 de la mañana la gente que usa las eco bicis son gente que sale de paseo de la reforma dirigiéndose hacia sus respectivos trabajos y a las 7 de la tarde es gente que regresa a su casa.

2. Lo que se hizo fue obtener la serie de tiempo de cada estación y se sacó el cambio con respecto la semana pasada.

3. La siguiente figura muestra una sección de la matriz origen-destino , donde se destacan la ciclo base 1 con arribo a la estación 18 y viceversa.

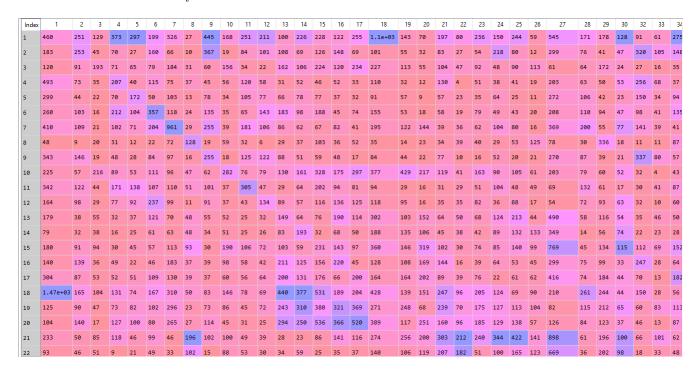


Figura 2: Sección de la matriz origen destino

Las siguiente figura muestra la ubicación de la estación 1 y 18, se puede observar que son estaciones cercanas. Se puede pensar que la estación 1 está en una zona de casa habitación mientras que la 18 está cerca de una avenida grande, lo que lleva a concluir que es gente que se quiere acercar a la avenida.



Figura 3: Muestra la relación entre la las estaciones 1 y 18

Un comportamiento similar se puede observar en las estaciones 21 y 27. Ambas estaciones se encuentran a corta distancia y sobre la misma ciclovía.

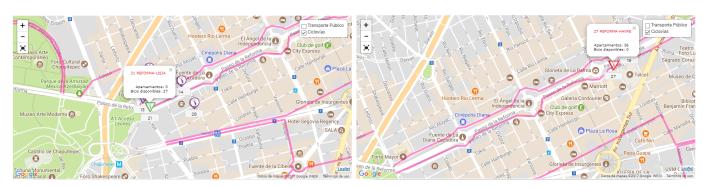


Figura 4: Muestra la relación entre la las estaciones 11 y 27

4. Para obtener los clusters se utilizó la técnica de K mean clustering, la figura que se muestra adelante muestra los diferentes clusters que se encontraron, además, del coeficiente de silhouette. Como se observa el cluster que mejor se acopla es el de k=2, lo que nos indica que se pueden agrupar las estaciones como las estaciones más recurrentes tanto de salida como de llegada y las que no son tan recurrentes.

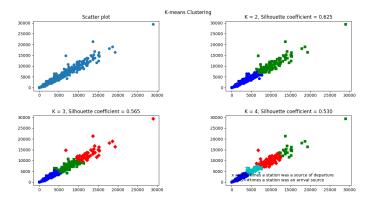


Figura 5: Clusters de las estaciones de ecobici

Se utilizo este método porque se quería ver el comportamiento de las estaciones como fuentes de salida y llegada, se pensó desde un principio que deberían de existir 2 clases de estaciones de acuerdo a su recurrencia y este método me pareció para identificar esa homogeneidad entre clusters.

Referencias

- http://www.beta.inegi.org.mx/proyectos/ccpv/2010/
- http://www.sedesol.gob.mx/work/models/SEDESOL/Sedesol/sppe/upri/dgapl/fais/Calculo/2013/ FAIS/Calculo_FAIS_2013.pdf
- http://cuentame.inegi.org.mx/poblacion/escolaridad.aspx?tema=P
- http://www.beta.inegi.org.mx/temas/natalidad/
- http://www.beta.inegi.org.mx/proyectos/registros/vitales/natalidad/
- http://www.beta.inegi.org.mx/proyectos/enchogares/especiales/enadid/2014/
- http://www.inegi.org.mx/saladeprensa/aproposito/2017/mujer2017_Nal.pdf